



**Министерство науки и высшего образования Российской  
Федерации  
Федеральное государственное бюджетное образовательное  
учреждение  
высшего образования  
«Московский государственный технический университет  
имени Н.Э. Баумана  
(национальный исследовательский университет)»  
(МГТУ им. Н.Э. Баумана)**

---

**Командный проект**

Название:

Обработка сигнала ЭКГ и прогнозирование состояния пациента при  
проведении СЛР аппаратным способом

Дисциплина:

Анализ временных рядов

*студент гр. БМТ1-11М / Безотосный Тихон Дмитриевич / \_\_\_\_\_*

*студент гр. БМТ1-11М / Коченов Андрей Сергеевич / \_\_\_\_\_*

*студент гр. БМТ1-11М / Кравченко Артем Олегович / \_\_\_\_\_*

*студент гр. БМТ1-11М / Яковлев Георгий Олегович / \_\_\_\_\_*

*студент гр. БМТ1-12М / Гордиенко Даниил Валерьевич / \_\_\_\_\_*

*студент гр. БМТ1-13М / Тлишева Зинаида Владимировна / \_\_\_\_\_*

**Москва 2023 г.**

## СОДЕРЖАНИЕ

СОДЕРЖАНИЕ .....	2
ПРЕАМБУЛА .....	3
ВВЕДЕНИЕ.....	4
1.1 Литобзор.....	5
1.2 Теоретическая часть.....	6
ОСНОВНАЯ ЧАСТЬ.....	10
2.1 Материалы и методы .....	10
2.2 Результаты.....	19
ЗАКЛЮЧЕНИЕ .....	20
СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ .....	21
ПРИЛОЖЕНИЕ .....	22

## **ПРЕАМБУЛА**

Развитие новых методов обработки сигналов ЭКГ может значительно повысить точность диагностики сердечных заболеваний, в частности, фибрилляции предсердий.

Целью курсового проекта является исследование и разработка методов обработки сигнала ЭКГ с использованием аппаратных средств для эффективного прогнозирования состояния пациента и постановки диагноза, создание автоматизированной системы, способной точно анализировать изменения в электрокардиографических данных в реальном времени, выявлять аномалии в сердечной активности и предоставлять прогноз относительно состояния сердечно-сосудистой системы. Работа направлена на повышение точности и надежности диагностики, а также на создание принципиально новых подходов к мониторингу сердечного состояния пациентов. Такие внедрения помогут исключить, или в какой-то мере свести к минимуму, возможность некорректной постановки диагноза.

Также стоит учитывать, что автоматизированные системы могут быть интегрированы в системы телемедицины, позволяя проводить стресс-тестирование и мониторинг сердечного состояния дистанционно. Это актуально в условиях распределенной медицины и может быть особенно полезным в случае удаленного местоположения пациента или необходимости долгосрочного мониторинга.

## **ВВЕДЕНИЕ**

На сегодняшний день медицинское оборудование позволяет оценить состояние сердца с высоким уровнем точности. Корректная оценка данных показателей является важной частью постановки диагноза о заболевании пациента. Благодаря развитию медицинских технологий задачи в этой области становятся все более актуальными. Множество людей сегодня носят фитнес-браслеты, наблюдающие за пульсом человека, продаются чехлы для телефонов, способные записывать ЭКГ сигнал. Анализируя эту информацию, можно вовремя распознать различные болезни и принять предупредительные меры. Одной из важных для дальнейшего анализа ЭКГ характеристик является состояние сна/бодрствования человека. В данной работе описан один из методов анализа ЭКГ сигнала, применительно к данной задаче.

Фибрилляция предсердий (ФП) – одна из наиболее часто встречающихся предсердных тахикардий. Это сердечное нарушение, при котором мышцы предсердий начинают сокращаться нерегулярно и асинхронно, вместо нормального координированного сокращения.

Вместо типичных сокращений мышц, на электрокардиограмме наблюдаются беспорядочные и быстрые дрожания, которые называют фибрилляцией.

При нормальном сердечном ритме на ЭКГ присутствует характерная волна Р, представляющая собой активацию(деполяризацию) предсердий. В случае фибрилляции предсердий, из-за беспорядочного и асинхронного сокращения предсердий, Р-волны часто отсутствуют или представлены как нерегулярные и мельчающие колебания.

Интервалы между последовательными QRS-комплексами (RR-интервалы) также становятся нерегулярными из-за беспорядочных импульсов, генерируемых в предсердиях.

Фибрилляция предсердий часто сопровождается высокой частотой сердечных сокращений, так как предсердия могут сокращаться на высокой частоте, приводя к беспорядочным импульсам в желудочках сердца.

Вместо типичных Р-волн на ЭКГ можно увидеть мерцательные волны, представляющие собой беспорядочные колебания, отражающие беспорядочное сокращение предсердий.

## **1.1 Литобзор**

Рекомендации [1] представляет собой важный вклад в область кардиологии, посвященный одному из наиболее распространенных сердечных нарушений – фибрилляции предсердий (ФП).

Особое внимание уделяется диагностике, включая роль современных методов обработки сигналов ЭКГ и использование передовых технологий в мониторинге сердечной активности.

Вместе с тем, данное пособие позволяет углубиться в теоретические аспекты функционирования самой сердечно-сосудистой системы.

Существует большое количество работ, связанных с возможным применением искусственного интеллекта для обработки и классификации сигнала ЭКГ.

Были разработаны нейронные сети SVM (), точность результатов была высокой (более 90%), но не было единой модели для классификации. В [2] для распознавания двух паттернов сердцебиения используются искусственные нейронные сети с прямой связью и полностью подключенные искусственные нейронные сети с поддержкой метода оптимизации роя частиц. Настройка параметров предлагаемого метода позволила повысить точность классификации до 96% по сравнению с аналогичным методом со значением параметров по умолчанию.

Использование сверточных нейронных сетей [10] показало, что данный метод может достичь лучших результатов обнаружения желудочковых аритмий, по сравнению с современными методами.

В Индонезии [3] наблюдается колоссально высокая смертность от сердечно-сосудистых заболеваний. Система «ТЕЛЕЭКГ» была создана для ранней диагностики и отслеживания сердечно-сосудистых заболеваний, это была первая реальная система классификации сердечбиений. Сервер был способен обрабатывать 60 запросов одновременно с точностью 94%.

В исследовании [8] ЭКГ сигнал был разложен на 9 типов сигналов с использованием различных частот вейвлет-преобразования с последующей фильтрацией шума и повторным восстановлением сигналов. Была использована 24-слойная сверточная нейронная сеть. С ее помощью были извлечены признаки, а затем были классифицированы данные для получения оценки F1 в 86,46%. У вейвлет преобразования есть 3 серьезных недостатка: чувствительность к сдвигу, плохая направленность и отсутствие информации о фазе.

Все исследования доказали, что алгоритмы машинного обучения очень эффективны при классификации и детекции заболеваний сердечно-сосудистой системы.

## **1.2 Теоретическая часть**

Электрокардиограмма (ЭКГ) представляет собой полное представление электрической активности сердца на поверхности тела человека, широко используемое в клинической диагностике заболеваний сердца и также используется в качестве индикатора для мониторинга функционирования сердечно-сосудистой системы. Анализ ЭКГ широко используется для выявления заболеваний сердца из-за простоты и неинвазивности исследования. Характеристики сигналов ЭКГ можно рассчитать по отведениям ЭКГ и извлечь с помощью некоторых программных

инструментов. Например, миллионы людей страдают от фибрилляции предсердий, что в некоторых случаях может привести не только к временному плохому самочувствию пациента, но и к летальному исходу. Поэтому точная и недорогая диагностика ФП сердца весьма желательна [4]. Во многих исследованиях разработаны подходы к классификации аритмий, в которых используются системы автоматического анализа и диагностики на основе сигналов ЭКГ. Наиболее важными факторами для анализа и диагностики заболеваний сердца являются извлечение признаков и классификация ударов. В последние годы были предложены многочисленные методы классификации сигналов ЭКГ, в которых достигнуты довольно хорошие результаты [4, 5, 6].

Эффективность классификации паттернов ЭКГ во многом зависит от способности характеризовать особенности, извлеченные из сигнала ЭКГ, и конструкции классификатора (модели классификации).

Ранее многие исследователи сообщали об автоматической классификации сердечных сокращений с использованием различных функций представления ЭКГ и ряда методов классификации. В общем, характеристики сердцебиения включают морфологию ЭКГ, характеристики интервалов сердцебиения (временные характеристики), корреляции сокращений и значения вершин [7].

Целью процесса классификации является получение модели, которая может классифицировать любой сигнал сердцебиения по определенному типу сердцебиения.

Одной из проблем является классификация данных, которая опирается на эффективно распределенные платформы обработки, методы интеллектуального анализа данных и машинного обучения.

Нейронная сеть – математическая модель, а также её программное или аппаратное воплощение, построенная по принципу организации и функционирования биологических нейронных сетей – сетей нервных клеток

живого организма. Это понятие возникло при изучении процессов, протекающих в мозге, и при попытке смоделировать эти процессы.

Нейронные сети представляют собой мощный инструмент в машинном обучении и искусственном интеллекте. Они спроектированы по аналогии с биологическими нейронами и способны обучаться и решать разнообразные задачи.

Основные типы нейронных сетей:

#### 1. Свёрточные нейронные сети (CNN).

Свёрточные нейронные сети являются идеальным выбором для обработки данных, имеющих пространственную структуру, таких как изображения и видео. Они используют свёрточные слои для выделения важных признаков из входных данных и пулинговые слои для уменьшения размерности. CNN широко применяются в задачах классификации изображений, распознавания объектов и детектирования лиц.

#### 2. Рекуррентные нейронные сети (RNN).

Рекуррентные нейронные сети предназначены для работы с последовательными данными, такими как тексты, речь и временные ряды. Они обладают внутренней памятью, которая позволяет им учитывать предыдущие состояния при обработке новых данных. RNN применяются в задачах машинного перевода, анализа текста и прогнозирования временных рядов.

#### 3. Генеративно-состязательные сети (GAN).

Генеративно-состязательные сети представляют собой два нейронных сетевых модуля - генератор и дискриминатор - которые соревнуются друг с другом. Генератор создаёт новые данные, а дискриминатор пытается различить реальные данные от сгенерированных. GAN используются для генерации изображений, анимации, стилей и многих других задач, связанных с синтезом данных.

#### 4. Рекуррентные свёрточные нейронные сети (RCNN).



RCNN объединяют в себе свойства как CNN, так и RNN. Они способны работать с последовательными данными и одновременно учитывать пространственные характеристики. Это позволяет им успешно справляться с задачами, такими как распознавание и анализ видео.

Для анализа электрокардиограммы в данной работе необходимо выбрать одну нейронную сеть, ориентированную на конкретную задачу. Основываясь на опыте из статьи [10] применим сверточные нейронные сети. Они хорошо справляются с проблемой больших размеченных данных. В работе предлагается использовать модель сверточной нейронной сети для создания представления функций на основе имеющихся необработанных данных ЭКГ.

В нашем случае, для решения задачи классификации уже подготовленного сигнала будем использовать сверточную нейронную сеть.

## ОСНОВНАЯ ЧАСТЬ

### 2.1 Материалы и методы

В качестве исследуемого сигнала используем данные сигналов электрической активности сердца, взятые с сайта «[www.kaggle.com](http://www.kaggle.com)».

Используем подмножество набора данных PTB-XL[9].

В файле «coorteeqsrfa.csv» в столбце «ritmi» находятся три диагноза:

- НОРМА (метка SR)
- ФИБРИЛЛЯЦИЯ ПРЕДСЕРДИЙ (метка AF) и все остальные
- РАЗЛИЧНЫЕ аритмии, суммированные только в один класс (метка VA).

Файл Numpy представляет собой ЭКГ сигнал в 12 различных отведениях пациентов, расположенных в файле «coorteeqsrfa».

Количество записей – 6528, ЭКГ выборка – 5000 (10-секундная запись при 500 Гц).

Классы составлены по ритмической диагностике из подмножества набора данных PTB-XL:

- SR 16782 синусовый ритм мерцательная аритмия мерцательная аритмия 1514 фибрилляция предсердий
- STACH 826 синусовая тахикардия
- SARRH 772 синусовая аритмия
- SBRAD 637 синусовая брадикардия
- PACE 296 нормально функционирующий искусственный кардиостимулятор
- SVARR 157 суправентрикулярная аритмия
- BIGU 82 бигеминальный рисунок (неизвестного происхождения, SV или желудочковая)

- AFLT 73 трепетание предсердий
- SVTAC 27 суправентрикулярная тахикардия
- PSVT 24 пароксизмальная суправентрикулярная тахикардия
- TRIGU 20 тройничный паттерн (неизвестного происхождения, SV или желудочковый)

Из SR берется всего 2000 записей, чтобы построить более сбалансированные датасеты, они дискретизируются без повторений. AF состоит из записей AFIB и AFLT 1587. BA – это все остальные виды аритмий, объединенные в один большой класс.

## ПОДГОТОВКА НАБОРА ДАННЫХ

В качестве входного сигнала имеем датасет с уже размеченными данными на ЭКГ сигнале. Из самого набора данных об ЭКГ сигнале необходимо получить спектрограмму для дальнейшей обработки уже полученного изображения. Для этого были подобраны определенные вейвлеты, проведение операции свертки с которой проявляет наилучшие результаты для получения спектрограммы. По визуализированной спектрограмме можно понять, какого рода присутствуют частоты на самом изображении. В качестве основных инструментов для анализа сигнала использовалось вейвлет-преобразование.

Вейвлет-преобразование (англ. Wavelet transform) – интегральное преобразование, которое представляет собой свертку вейвлет-функции с сигналом. Вейвлет-преобразование переводит сигнал из временного представления в частотно-временное.

Способ преобразования функции (или сигнала) в форму, которая или делает некоторые величины исходного сигнала более поддающимися изучению, или позволяет сжать исходный набор данных. Вейвлетное преобразование сигналов является обобщением спектрального анализа.

Термин (англ. wavelet) в переводе с английского означает «маленькая волна». Вейвлеты – это обобщённое название математических функций определенной формы, которые локальны во времени и по частоте, в которых все функции получаются из одной базовой, изменяя её (сдвигая, растягивая).

Для анализа данных будем использовать следующие вейвлеты.

### **Вейвлет Морле.**

Вейвлет Морле (или вейвлет Габора) представляет собой вейвлет, состоящий из комплексной экспоненты, умноженной на окно Гаусса, представлен на рисунке 1.




Рисунок 1. Визуализация вейвлета Морле.

При визуализации методом магнитно-резонансной спектроскопии метод вейвлет-преобразования Морле предлагает интуитивно понятный мост между информацией о частоте и времени, который может прояснить интерпретацию сложных спектров травм головы, полученных с помощью преобразования Фурье. Вейвлет-преобразование Морле, однако, предназначено не как замена преобразованию Фурье, а скорее как дополнение, обеспечивающее качественный доступ к изменениям, связанным со временем, и использующее преимущества множества измерений, доступных в анализе спада свободной индукции.[10]

Применение вейвлет-анализа Морле также используется для определения аномального поведения сердцебиения на электрокардиограмме (ЭКГ). Поскольку изменение аномального сердцебиения является нестационарным сигналом, этот сигнал подходит для анализа на основе вейвлетов.

### **Вейвлет «Мексиканская шляпа».**

Вейвлет "Мексиканская шляпа" (Mexican Hat Wavelet) также известен как вейвлет Риккера. Название "Мексиканская шляпа" происходит от формы вейвлета, которая напоминает широкий и плоский конус, похожий на мексиканскую шляпу, представлен на рисунке 2.




Рисунок 2. Визуализация вейвлета «Мексиканская шляпа»

Формула для вейвлета "Мексиканская шляпа" в одномерном случае может быть задана следующим образом:

$$\psi(t) = (1 - t^2)e^{-\frac{t^2}{2}}.$$

Вейвлет "Мексиканская шляпа" обладает свойством нулевого среднего значения, которое может быть полезно в определенных приложениях. Он также обеспечивает хорошую локализацию как во времени, так и в частотной области. Эти свойства делают его эффективным инструментом для анализа

сигналов и изображений, особенно в задачах, связанных с локальными изменениями или структурами в данных.

### **Вейвлет Шеннона.**

В теории сигналов и обработке сигналов вейвлеты Шеннона (Shannon) часто ассоциируются с функцией sinc (от англ. sine cardinal). Функция sinc определена как:

$$\text{sinc}(t) = \frac{\sin(\pi t)}{\pi t}.$$

Графическое представление вейвлета Шеннона изображено на рисунке 3.




Рисунок 3. Визуализация вейвлета Шеннона

Спектральная ширина функции sinc() в частотной области равна единице, что связано с тем, что периодичность синуса приводит к основной частоте, и sinc учитывает это в своем определении.

Связанный с этой функцией вейвлет Шеннона определен как производная функции sinc:

$$\psi(t) = \frac{d}{dt} \text{sinc}(t).$$

Он может быть записан как:

$$\psi(t) = \frac{\pi \cos(\pi t)}{(\pi t)^2} - \frac{\sin(\pi t)}{(\pi t)^3}.$$

Выбор данных вейвлетов обусловлен возможностью использования их на непрерывных сигналах, в отличие от других вейвлетов (Добеши, биортогональный), рассчитанных на дискретный сигнал.

## ОБРАБОТКА ДАННЫХ

Как уже говорилось, данные ЭКГ представлены в виде двумерного массива NumPy, где каждая строка соответствует одному отведению. Таким образом, у нас есть 12 отведений, и каждое значение в массиве представляет амплитуду в милливольтках, рисунок 4.

```
array([[[ -0.05 , -0.05 , -0.05 , ..., -0.082, -0.078, -0.074],
        [ 0.09 , 0.09 , 0.09 , ..., -0.022, -0.018, -0.014],
        [ 0.14 , 0.14 , 0.14 , ..., 0.06 , 0.06 , 0.06 ],
        ...,
        [-0.055, -0.055, -0.055, ..., -0.081, -0.078, -0.075],
        [ 0. , 0. , 0. , ..., -0.102, -0.1 , -0.099],
        [-0.125, -0.125, -0.125, ..., -0.05 , -0.05 , -0.049]],

       [[ 0.75 , 0.75 , 0.75 , ..., -0.06 , -0.074, -0.085],
        [ 0.335, 0.335, 0.335, ..., -0.045, -0.059, -0.07 ],
        [-0.415, -0.415, -0.415, ..., 0.015, 0.015, 0.015],
        ...,
        [ 1.54 , 1.54 , 1.54 , ..., -0.13 , -0.13 , -0.13 ],
        [ 1.01 , 1.01 , 1.01 , ..., -0.09 , -0.09 , -0.09 ],
        [ 0.57 , 0.57 , 0.57 , ..., 0.015, 0.015, 0.015]])
```

Рисунок 4. Пример данных с 12 отведений

Выведем 12 графиков, каждый из которых соответствует одному отведению.

Такие графики строятся с использованием библиотеки Matplotlib. Каждый график отображает временной ход для соответствующего отведения, они представлены на рисунке 5.




Рисунок 5. Вывод 12 отведений на отдельных графиках

В этом случае, 12 отведений представлены на одном графике. Каждый график смещен на максимальное значение амплитуды, и значения амплитуды приведены к диапазону от 0 до 255, используя uint8 кодировку.




Полученные графики представлены на рисунке 6.

Рисунок 6. Изображение, сохраняемое в NumPy массив uint8.


Для расчета и визуализации электрокардиограммы (ЭКГ) в трехмерном пространстве часто используется метод построения векторного трехмерного линейного пространства (3D Vectorcardiography). Одной из стандартных техник для этого является векторная ЭКГ (Vector ECG или VCG).

Основной идеей VCG является использование трех осей, представляющих направление преходящего электрического тока в теле. Обычно это три оси - вертикальная, горизонтальная и лежащая вдоль переднего/заднего направления. Векторы, соответствующие различным моментам во времени, строятся в этом трехмерном пространстве.

Функция принимает данные ЭКГ (ECG), номер R-зубца для начала и конца анализа (`n_term_start` и `n_term_finish`). Возвращает `DataFrame` с координатами вектора ВЭКГ (`df_result`). Функция также выводит кардиоиды для 3 плоскостей и интерактивную трехмерную кардиоиду, если параметры инициализации заданы соответствующим образом, рисунок 7.



А.



Б.

Рисунок 7. А – проекции кардиоиды на 3 плоскости, Б – трехмерная интерактивная кардиоида.

# КЛАССИФИКАЦИЯ С ИСПОЛЬЗОВАНИЕМ МАШИННОГО ОБУЧЕНИЯ

## **2.2 Результаты**

## **ЗАКЛЮЧЕНИЕ**

## СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

- [1] Сулимов В.А., Голицин В.П., Панченко Е.П. и др. Диагностика и лечение фибрилляции предсердий. Рекомендации РКО, ВНОА, АССХ. - Москва, 2013. - 112 с.
- [3] Инсе Т., Кираньяз С., Габбуж М. Универсальная и надежная система для автоматической классификации сигналов ЭКГ для конкретного пациента. IEEE Trans Biomed Eng. 2009;56(5):1415-26.
- [2] Ма'Сум М.А., Джатмико У., Сухартанто Х. Усовершенствованная система ТЕЛЕЭКГ с использованием фреймворка hadoop для обработки больших данных. В: международный семинар по большим данным и информационной безопасности 2016 года (IWBIS). Нью-Йорк: IEEE; 2016. стр. 121-6.
- [4] Качуи М., Фазели С., Саррафзаде М. Классификация сердцебиения на ЭКГ: глубокое переносимое представление. В: международная конференция IEEE по информатике здравоохранения (ICHI) 2018 года. Нью-Йорк: IEEE; 2018. стр. 443-4.
- [5] Чжао З., Ян Л., Чен Д., Ло Ю. Система идентификации ЭКГ человека, основанная на ансамблевом разложении эмпирического режима. Датчики. 2013;13(5):6832-64.
- [6] Valenza G, Greco A, Citi L, Bianchi M, Barbieri R, Scilingo E. Неоднородные точечные процессы для мгновенной оценки эмоционального тактильного восприятия с помощью информации о динамике сердцебиения. Sci Rep. 2016; 6:28567.

- [7] Христов И., Екова И., Бортолан Г. Классификация преждевременных сокращений желудочков по правилу k-го ближайшего соседа. Физиологические показатели. 2005;26(1):123.
- [8] ECG Classification using Deep Convolutional Neural Networks and Data Analysis
- [9]«<https://www.kaggle.com/datasets/arjunascagnetto/ptbxl-atrial-fibrillation-detection/discussion>»
- 10 Convolutional Neural Networks for Electrocardiogram Classification // Mohamad M. Alrahhal
- 11 <http://cds.ismrm.org/ismrm-2001/PDF3/0822.pdf>[Голый URL PDF]

## **ПРИЛОЖЕНИЕ 1**

## **ПРИЛОЖЕНИЕ 2**

## **ПРИЛОЖЕНИЕ 3**